

Taller — Predicción de accidentalidad

Clasificación binaria · Manejo de clases desbalanceadas · Datos en SQLite

Tema: Predicción de accidentalidad por barrio y hora

Modalidad: Grupal

Fecha de entrega: mayo 15 2026 5:00PM

Datos (SQLite): [Link de descarga](#)

Entregables: Informe en PDF + Notebook (.ipynb) con todo el código vía EAFIT interactiva

1. Contexto del problema

Las administraciones municipales necesitan anticipar dónde y cuándo es más probable que ocurra un accidente de tránsito para focalizar operativos, agentes y campañas de prevención. El reto no es trivial: la mayoría de las combinaciones (barrio, hora) no presentan accidentes, y solo una pequeña fracción sí los registra. En otras palabras, el problema es por naturaleza un problema de clases desbalanceadas.

En este taller usted recibe una base de datos en SQLite con tres tablas que combinan información cruda de accidentes, una agregación por barrio y hora, y mediciones climáticas de cada barrio en cada hora. Su tarea es construir un modelo de clasificación binaria que prediga si en un barrio determinado, a una hora determinada, va a ocurrir o no un accidente.

2. Datos disponibles

La base de datos SQLite contiene tres tablas. Antes de modelar, debe entenderlas, validarlas y unir las adecuadamente.

2.1 Tabla raw_accidentes

Información detallada de cada accidente reportado. Cada fila es un accidente.

Columna	Tipo	Descripción
TW	TIMESTAMP	Fecha-hora truncada del registro
FECHA	TEXT	Fecha original del accidente
HORA	TEXT	Hora original del accidente
Hora_num	INTEGER	Hora del día (0-23)

Columna	Tipo	Descripción
Dia, Mes	INTEGER	Componentes calendario
MES_NOMBRE	TEXT	Nombre del mes
Dia_sem	TEXT	Día de la semana
PERIODO	INTEGER	Año del registro
BARRIO, COMUNA	TEXT	Localización administrativa
Lat, Lon	REAL	Coordenadas del accidente
CLASE, GRAVEDAD, DISEÑO	TEXT	Tipo del accidente, gravedad y diseño vial
DIRECCION, OBJECTID, RADICADO	TEXT/INT	Identificadores y dirección

2.2 Tabla accidentes

Versión agregada: indica que existió al menos un accidente en (barrio, hora). Esta es la fuente natural para construir la variable objetivo.

Columna	Tipo	Descripción
TW	TIMESTAMP	Marca temporal (truncada a la hora)
BARRIO	TEXT	Barrio donde ocurrió el accidente
Lat, Lon	REAL	Coordenadas representativas del barrio
Dia_sem	TEXT	Día de la semana
Mes, Dia, Hora	INTEGER	Componentes de la marca temporal

2.3 Tabla clima

Mediciones meteorológicas por barrio y hora — una fila por cada combinación (barrio, hora) que se quiera modelar.

Columna	Tipo	Descripción
TW, BARRIO	TEXT	Llaves de cruce con las otras tablas
summary, icon	TEXT	Descripción del clima
temperature	REAL	Temperatura (°C/°F según fuente)
apparentTemperature	REAL	Sensación térmica
dewPoint, humidity	REAL	Punto de rocío y humedad relativa

Columna	Tipo	Descripción
precipIntensity, precipProbability	REAL	Intensidad y probabilidad de precipitación
windSpeed, windBearing	REAL	Velocidad y dirección del viento
cloudCover, uvIndex, visibility	REAL	Nubosidad, índice UV y visibilidad

Importante: la tabla **accidentes** contiene únicamente las horas-barrio en que SÍ hubo accidente. Para el problema supervisado debe construir también los casos negativos (sin accidente) cruzando con la tabla **clima**, que sí cubre todas las combinaciones (barrio, hora). El target se define como 1 si la pareja (barrio, hora) está en **accidentes**, 0 en caso contrario.

3. Pregunta a responder

*¿Cuál es la probabilidad de que ocurra al menos un accidente en el barrio **B** a la hora **h** del día?*

Construya una variable objetivo binaria a partir del cruce barrio $\times$ hora durante el período disponible. Documente claramente:

- ¿Cómo definió la unidad de análisis (resolución temporal y geográfica)?
- ¿Cómo construyó los casos negativos (parejas sin accidente)?
- ¿Qué proporción quedó de la clase positiva? Esto motiva el resto del trabajo.

4. Tareas a desarrollar

4.1 Análisis exploratorio (EDA)

- Distribución temporal: accidentes por hora del día, día de la semana, mes.
- Distribución espacial: barrios/comunas con mayor concentración.
- Caracterización del clima: temperatura, lluvia, viento; correlación con accidentalidad.
- Estadísticas descriptivas y visualizaciones que justifiquen las decisiones de modelado.

4.2 Calidad de datos

- Verifique la consistencia entre las tres tablas: formato de TW, nombres de barrios, duplicados y llaves de cruce.
- Identifique valores faltantes, duplicados, inconsistencias y valores atípicos.

- Documente cómo abordó cada problema y por qué.

4.3 Unión de tablas e ingeniería de características

- Una las tablas sobre las llaves (BARRIO, TW). Justifique el tipo de join elegido.
- Genere variables temporales: hora del día, día de la semana, mes, fin de semana, festivo.
- Codifique variables cíclicas con seno/coseno (hora, día de la semana, día del año).
- Considere variables agregadas por barrio: número promedio de accidentes históricos, comuna, etc.
- Use las variables climáticas que considere relevantes — justifíquelo con el EDA.
- Maneje variables categóricas (BARRIO, summary, icon) con la codificación que prefiera (one-hot, target encoding, frecuencia).
- Toda variable histórica debe calcularse únicamente con información disponible antes del momento de predicción para evitar la fuga de información temporal.

4.4 Modelo no sesgado

- Construya un baseline ingenuo y muestre por qué la accuracy no es la métrica adecuada.
- Implemente al menos dos estrategias de balanceo y compárelas:
- Compare al menos tres familias de modelos (por ejemplo: Logística, Random Forest, Gradient Boosting). Realice el ajuste de hiperparámetros mediante una validación adecuada.

4.5 Métricas adecuadas

- Seleccione métricas adecuadas para el modelo
- Incluya la matriz de confusión correspondiente al umbral final elegido.

4.6 Validación

- Use la partición temporal como validación principal: entrene con los primeros meses y valide con los últimos. Complemente con validación cruzada estratificada sin introducir fuga de información.
- Reporte el desempeño promedio y su variabilidad entre folds.

4.7 Selección del modelo final

- Justifique con base en métricas, en la estabilidad y en el costo computacional.
- Discuta cómo el ajuste del umbral cambia el equilibrio de precisión y recall según el costo de cada error.
- Si hay una métrica de negocio (p. ej., costo de no detectar un accidente), elija el umbral que la optimice.

4.8 Caso de uso

- Proponga cómo se usaría el modelo en operación: por ejemplo, una alerta diaria con los Top-N barrios y las horas de mayor riesgo, o un mapa de calor por hora.

-
- Discuta las limitaciones del modelo: sesgos en los datos, deriva temporal, interpretabilidad.
 - Sugiera variables externas que, si estuvieran disponibles, mejorarían el modelo.

5. Entregables

5.1 Informe en PDF

Debe incluir:

1. Resumen ejecutivo
2. Descripción del problema y de los datos.
3. Resultados del análisis exploratorio (con gráficos).
4. Tratamiento de la calidad de los datos y de las decisiones tomadas.
5. Ingeniería de características — qué creó y por qué.
6. Modelos comparados, hiperparámetros, métricas.
7. Estrategia de balanceo elegida y justificación.
8. Modelo final, métricas, matriz de confusión y umbral de decisión.
9. Caso de uso propuesto y limitaciones.
10. Conclusiones y trabajo futuro.

5.2 Notebook (.ipynb)

- Conexión a la base de datos SQLite con sqlite3 o SQLAlchemy.
- Carga de las tablas mediante consultas SQL (no asuma archivos CSV intermedios).
- Todo el flujo: EDA → calidad → unión → features → modelado → métricas → caso de uso.
- Código modular y debidamente comentado en español. Funciones reutilizables.
- Reproducibilidad: fije el `random_state`, declare las versiones, evite las rutas absolutas.
- Las celdas deben ejecutarse en orden y sin errores.

Plantilla sugerida de conexión

```
import sqlite3, pandas as pd
con = sqlite3.connect('accidentes.sqlite')
accidentes = pd.read_sql('SELECT * FROM accidentes', con, parse_dates=['TW'])
clima = pd.read_sql('SELECT * FROM clima', con, parse_dates=['TW'])
raw = pd.read_sql('SELECT * FROM raw_accidentes', con, parse_dates=['TW'])
con.close()
```

6. Rúbrica de evaluación

***Aprendizaje Automático
Taller, Semestre 2026-1
Profesor: Pablo Saldarriaga / Marco Teran***

La nota se reparte así:

Criterio	Peso	Qué se evalúa
Análisis exploratorio y calidad de datos	15 %	Profundidad, claridad de hallazgos, manejo de problemas detectados
Ingeniería de características	15 %	Variables creadas, justificación, codificación adecuada
Manejo del desbalance	20 %	Estrategias probadas, comparación correcta, ajuste de umbral
Modelado y validación	20 %	Modelos comparados, validación correcta, hiperparámetros
Métricas y selección del modelo final	10 %	Uso de métricas adecuadas y justificación clara del modelo final
Caso de uso y limitaciones	10 %	Aplicabilidad realista, límites del modelo
Calidad del informe y del notebook	10 %	Redacción, organización, código limpio y comentado