

Prediccion de Accidentalidad Vial en Medellin

Taller — Aprendizaje Automatico MCDA 2026-1 — Grupo 5

Entrega: mayo 15 de 2026

1. Resumen Ejecutivo

En este taller trabajamos con datos reales de accidentalidad vial de Medellin para construir un modelo que prediga si en un barrio especifico va a ocurrir un accidente a una hora determinada del dia. El dataset tenia mas de 1,5 millones de registros, pero solo el 1,51 % de ellos son accidentes reales — lo cual hace el problema bastante dificil porque los modelos tipicamente ignoran esos casos raros si no se les ayuda. Despues de probar tres algoritmos diferentes y ajustar varios parametros, encontramos que el mejor modelo fue un Random Forest con el umbral de decision bajado a 0,25, que logro detectar el 76 % de los accidentes reales (AUC-ROC 0,6562). Eso significa que, en la practica, el sistema podria anticipar 3 de cada 4 incidentes y permitirle a la Secretaria de Movilidad desplegar agentes de forma preventiva.

2. Descripcion del Problema y los Datos


La pregunta que teniamos que responder era: dado un barrio y una hora del dia, ¿que tan probable es que ocurra un accidente? Para eso construimos una variable objetivo binaria: 1 si hubo accidente en esa combinacion (barrio, hora), 0 si no. Lo mas interesante fue que los casos negativos (sin accidente) no estaban explicitamente en los datos — tuvimos que generarlos nosotros cruzando la tabla de clima (que si tiene todas las combinaciones posibles) con la tabla de accidentes via LEFT JOIN. El resultado fue que solo el 1,51 % de los registros son positivos, lo que nos obliga a usar metricas y estrategias distintas a las habituales.

Tabla	Descripcion	Filas aprox.
raw_accidentes	Cada fila es un accidente reportado con fecha, hora, barrio y coordenadas.	~50 000
accidentes	Version agregada: nos indica que en ese (barrio, hora) si hubo accidente.	~8 000
clima	Mediciones meteorologicas por (barrio, hora): la usamos como base del dataset.	~1 570 000

3. Analisis Exploratorio de Datos (EDA)

3.1 Distribucion Temporal

Lo primero que notamos al explorar los datos es que los accidentes no ocurren al azar a lo largo del dia. Hay dos picos muy claros: uno en la manana entre las 6:00 y las 9:00 horas (cuando la gente va al trabajo) y otro en la tarde entre las 17:00 y las 20:00 (cuando regresa). Entre las 2:00 y las 5:00 de la madrugada hay muy pocos accidentes, lo cual tiene todo el sentido. Los dias de semana concentran mas incidentes que el fin de semana, y el patron se mantiene estable a lo largo de 2017-2019, lo que nos da confianza en la calidad de los datos.



3.2 Distribucion Espacial

No todos los barrios tienen el mismo nivel de riesgo. La Candelaria resulto ser la zona con mayor concentracion de accidentes en practicamente todas las horas del dia, seguida de Laureles-Estadio, Castilla y El Poblado. Esto sugiere que hay características propias de cada barrio (densidad vial, velocidad permitida, tipo de intersecciones) que el modelo actualmente no puede capturar porque excluimos el barrio como variable — algo que identificamos como una mejora importante para versiones futuras.




Fig. 2. Mapa de calor: top-10 comunas x hora del dia. La Candelaria domina claramente en todas las franjas.

3.3 Variables Climaticas y Desbalanceo

En cuanto al clima, la variable que mas correlaciona con la ocurrencia de accidentes es la intensidad de la lluvia (precipIntensity), con un coeficiente de Pearson mayor a 0,06 — que puede sonar pequeno, pero en un dataset de este tamaño es significativo. La temperatura también tiene correlacion positiva: las horas mas calidas del dia coinciden con mas trafico y mas accidentes. El viento, en cambio, no parece tener mayor impacto. El grafico tambien nos muestra algo que fue clave para todas las decisiones de modelado: el desbalanceo es brutal. El 98,49 % de los registros son "sin accidente", lo que hace que la Accuracy sea completamente inutil como metrica.




Fig. 3. Solo el 1,51 % de los registros son accidentes. La intensidad de lluvia es el predictor climatico mas relevante.

4. Calidad de Datos

Antes de modelar tuvimos que resolver varios problemas que encontramos al cruzar las tres tablas. El mas frecuente fue la inconsistencia en los nombres de barrios (mayusculas, tildes, espacios extra), que hacia que el mismo barrio apareciera como entidades distintas y el JOIN no funcionara bien.

Problema	Como lo resolvimos
Inconsistencias en nombres de barrios	Normalizacion: strip(), upper() y eliminacion de tildes
Nulos en variables climaticas	Imputacion con 0 (sin lluvia = 0 es semanticamente correcto)
Duplicados en tabla accidentes	Deduplicacion por (barrio, hora), conservando el mas reciente
Barrios sin datos climaticos	Se excluyeron del dataset final (LEFT JOIN desde tabla clima)

5. Ingenieria de Caracteristicas

Construimos 14 variables de entrada agrupadas en dos tipos:

- Hora del dia — ciclica: uno de los aportes tecnicos mas importantes del trabajo. Si metemos la hora como un numero del 0 al 23, el modelo interpreta que las 11pm (hora 23) y las 12am (hora 0) estan muy lejos entre si, cuando en realidad son consecutivas. La solucion es transformarla con seno y coseno: $\text{hora_sin} = \sin(2\pi * \text{Hora}/24)$ y $\text{hora_cos} = \cos(2\pi * \text{Hora}/24)$. Esto le permite al modelo entender que el tiempo es circular, no lineal.
- Variables climaticas (10): precipIntensity, precipProbability, temperature, apparentTemperature, dewPoint, humidity, windSpeed, windBearing, cloudCover y uvIndex. Las seleccionamos todas porque el EDA mostro correlacion con la accidentalidad y el modelo de Random Forest puede filtrar las irrelevantes automaticamente.
- BARRIO no se incluyo porque tiene demasiadas categorias unicas y porque codificarlo correctamente (sin que el modelo "vea el futuro") requiere tecnicas especiales de target encoding con proteccion temporal que dejamos para trabajo futuro.

6. Modelos Comparados, Hiperparametros y Metricas

Probamos tres modelos diferentes para poder comparar y elegir el mejor. Usamos busqueda aleatoria de hiperparametros (RandomizedSearchCV) con validacion cruzada estratificada de 3 folds sobre una muestra de 100.000 registros, usando F1-Score de la clase positiva como criterio de seleccion — no Accuracy.

Modelo	Hiperparametros principales	F1(+)	AUC-ROC	Accuracy
Regresion Logistica	C=1, solver=saga, class_weight=balanced	0,0495	0,6517	0,7455
Random Forest	n_estimators=100, max_depth=10, cw=balanced	0,0456	0,6562	0,9122
Gradient Boosting	max_iter=100, learning_rate=0,2, max_depth=5	0,0505	0,6516	0,7787

Un modelo que siempre predice "sin accidente" logra el 98,49 % de Accuracy. Por eso la Accuracy no sirve aqui — un modelo totalmente inutil se veria excelente con esa metrica. Hay que mirar el AUC-ROC y el F1-Score de la clase positiva.




Fig. 4. Curvas ROC comparativas de los tres modelos. El Random Forest logra el mayor AUC-ROC (0,6562).

7. Estrategia de Balanceo y Validacion Temporal

7.1 Estrategia de Balanceo (Punto 4.5)

Solo el 1,51 % de los pares (barrio, hora) corresponden a eventos con accidente. Sin ninguna correccion, un modelo aprende a predecir siempre "sin accidente" y obtiene una accuracy del 98,49 % sin haber aprendido absolutamente nada util. Para contrarrestar esto se aplico la estrategia `class_weight="balanced"`, que ajusta automaticamente los pesos de cada clase durante el entrenamiento: los errores sobre la clase minoritaria (accidentes reales) se penalizan mas que los errores sobre la clase mayoritaria. Esta tecnica no modifica los datos originales ni genera registros sinteticos, sino que redefine la funcion de perdida del modelo para que ponga mayor atencion en los accidentes reales. Adicionalmente, se implemento SMOTE (Synthetic Minority Oversampling Technique) como estrategia complementaria, la cual genera ejemplos sinteticos de la clase minoritaria interpolando entre vecinos reales en el espacio de caracteristicas; los resultados de ambas estrategias se compararon mediante F1-Score y ROC-AUC.

7.2 Validacion Temporal (Punto 4.6)

Se utilizo una particion cronologica en lugar de una division aleatoria. Los datos fueron ordenados por la marca temporal TW y se definio un corte en el percentil 80 del tiempo: los primeros meses se usaron para entrenamiento y los ultimos para evaluacion. Esta decision es fundamental porque los datos de accidentalidad presentan dependencia temporal: los patrones de un mes influyen en los meses siguientes. Una division aleatoria mezclaria registros de fechas futuras dentro del entrenamiento, lo que constituye fuga de informacion temporal (data leakage). El objetivo es que la evaluacion simule fielmente el escenario real de operacion: el modelo siempre predice sobre datos del futuro, nunca sobre datos que ya vio durante el entrenamiento.

8. Modelo Final, Metricas y Umbral de Decision

Aqui viene una de las decisiones mas importantes: el umbral de decision. Por defecto, los modelos clasifican como accidente cuando la probabilidad supera el 50 % — pero con datos tan desbalanceados casi nunca pasa eso. Nosotros definimos una metrica de negocio: no detectar un accidente real cuesta 50 veces mas que lanzar una falsa alarma (porque el costo humano de un accidente no prevenido es mucho mayor que el de un operativo innecesario). Con esa logica, encontramos que el umbral optimo es 0,25, no 0,50.

Modelo	Umbral	Precision	Recall	F1	AUC-ROC	Costo/1000
Regresion Logistica	0,45	0,0251	0,6700	0,0483	0,6517	~702
Random Forest *	0,25	0,0245	0,7591	0,0475	0,6562	701,95
Gradient Boosting	0,30	0,0245	0,7246	0,0475	0,6516	701,95

* Modelo seleccionado: Random Forest con umbral 0,25.

Con el umbral en 0,25 el Random Forest detecta 20.149 de los 26.543 accidentes reales del conjunto de prueba (recall del 75,91 %). Si hubieramos dejado el umbral en 0,50, el recall habria sido practicamente 0 %. La grafica siguiente lo muestra claramente: a medida que

bajamos el umbral, el recall sube pero la precision cae — el minimo de costo operacional se da en 0,25.




Fig. 5. Tradeoff precision-recall y costo operacional vs umbral para Random Forest. El minimo de costo esta en 0,25.

Matrices de Confusion al Umbral Optimo por Modelo




Fig. 6. Matrices de confusion de los tres modelos al umbral optimo. El Random Forest (umbral 0,25) detecta el 75,91 % de los accidentes reales.

9. Caso de Uso y Limitaciones

9.1 Como funcionaria en la practica

La idea es que el sistema funcione como una alerta diaria para la Secretaria de Movilidad. Cada mañana, antes de las 6:00, el sistema tomaria el pronostico climatico de cada barrio para las proximas 24 horas, construiria las 14 variables de entrada y correria el modelo. El resultado seria una lista de los barrios y horas con mayor probabilidad de accidente ese dia, y con esa lista la Secretaria podria decidir donde poner agentes de transito, operativos preventivos o senales temporales. A continuacion se muestra el mapa de calor barrio x hora generado con los datos del conjunto de prueba, y en el notebook (celdas 51 y 52) esta el ranking completo de los 15 barrios mas riesgosos.




Fig. 7. Mapa de calor: probabilidad media de accidente por barrio y hora del dia (top-10 barrios del periodo de prueba).

9.2 Limitaciones honestas del modelo

- La precision es muy baja (~2,5 %). En terminos practicos, de cada 100 alertas que lanza el modelo, solo 2 o 3 son accidentes reales. Eso es un monton de falsas alarmas — habria que ver si la Secretaria tiene capacidad operativa para eso.
- El modelo no sabe nada de lo que pasa en cada barrio especificamente. Excluimos BARRIO de las variables, entonces dos barrios muy distintos con el mismo clima y la misma hora reciben la misma prediccion. Es una simplificacion grande.
- Los datos son de 2017-2019. Si los patrones de movilidad cambiaron (pandemia, obras nuevas, cambios de infraestructura), el modelo podria quedar desactualizado.

- No es interpretable facilmente. Un Random Forest no nos puede decir "el accidente va a ocurrir porque esta lloviendo a las 7am en La Candelaria". Para eso habria que complementarlo con tecnicas como SHAP values.

10. Conclusiones y Trabajo Futuro

Al final, creemos que el trabajo logra lo que se pedia: construir un modelo que funcione mejor que el azar para predecir accidentalidad vial en Medellin, manejando correctamente el desbalanceo de clases y usando una validacion que no introduce trampa. Estas son las conclusiones principales que nos llevamos:

- La Accuracy no sirve en este problema. Un modelo que nunca predice accidente logra el 98,49 % de Accuracy — si nos hubieramos guiado por esa metrica, habriamos entregado un modelo completamente inutil sin darnos cuenta.
- Transformar la hora con seno y coseno si importa. Sin esa transformacion, el modelo interpretaria que las 11pm y las 12am son momentos muy distintos, cuando en realidad son consecutivos. Es un detalle tecnico pequeno pero que afecta la calidad de las predicciones.
- La division temporal de los datos no es opcional. Si hubieramos dividido aleatoriamente entrenamiento y prueba, las metricas habrian sido artificialmente mejores y el modelo habria fallado al usarse en datos nuevos reales.
- El umbral de decision es tan importante como el algoritmo. Ajustarlo de 0,50 a 0,25 — guiado por una metrica de negocio real — fue lo que permitio pasar de un recall de casi 0 % a un recall del 76 %. Sin ese paso, el mejor algoritmo del mundo habria sido practicamente inutilizable.
- El Random Forest fue el modelo final, no porque sea el "mejor" en abstracto, sino porque bajo nuestra metrica de negocio (costo FN = 50 x FP, recall minimo 30 %) fue el que minimizo el costo operacional con el umbral ajustado.

Que hariamos diferente o mejor con mas tiempo

- Incluir BARRIO como variable usando target encoding con proteccion temporal. Ese solo cambio probablemente mejoraria bastante el AUC-ROC porque el historial de accidentalidad de cada barrio es mucho mas informativo que el clima.
- Conseguir mas variables externas: flujo vehicular en tiempo real, eventos masivos (conciertos, partidos), estado de la via, luminosidad del sector. El clima solo explica una parte pequena de la variabilidad.
- Explorar modelos de series de tiempo como LSTM o Temporal Fusion Transformers, que podrian capturar dependencias temporales que los modelos actuales ignoran.
- Hacer una prueba piloto real con la Secretaria de Movilidad para ver si el modelo efectivamente ayuda a reducir accidentes cuando se usa en la practica.